

# Analisis Perbandingan Model ARIMA dan Exponential Smoothing dalam Meramalkan Harga Penutupan Saham

Arif Rahman Abdul Aziz\*, Putri Taqwa Prasetyaningrum

Fakultas Teknologi Informasi, Sistem Informasi, Universitas Mercu Buana Yogyakarta, Yogyakarta, Indonesia

Email: <sup>1,\*</sup>211210022@student.mercubuana-yogya.ac.id, <sup>2</sup>putri@mercubuana-yogya.ac.id

Email Penulis Korespondensi: 211210022@student.mercubuana-yogya.ac.id

Submitted: 30/04/2025; Accepted: 31/05/2025; Published: 01/06/2025

**Abstrak**—Pasar saham merupakan salah satu instrumen investasi yang sangat diminati karena potensi keuntungan yang tinggi. Namun, fluktuasi harga saham yang signifikan juga membawa risiko yang besar, yang dipengaruhi oleh berbagai faktor seperti kondisi ekonomi makro, kebijakan pemerintah, laporan keuangan perusahaan, serta sentimen pasar. Oleh karena itu, analisis dan peramalan harga saham menjadi aspek penting bagi investor dan pelaku pasar dalam membuat keputusan investasi yang lebih tepat. Penelitian ini fokus pada saham PT Indosat Ooredoo Hutchison Tbk (ISAT), yang menunjukkan volatilitas tinggi, terutama setelah penurunan tajam harga saham pada akhir Februari 2025, yang diduga dipicu oleh ketidaksesuaian laporan keuangan dengan ekspektasi analis. Tujuan utama dari penelitian ini adalah untuk membandingkan dua metode peramalan deret waktu yang sering digunakan, yaitu Autoregressive Integrated Moving Average (ARIMA) dan Exponential Smoothing dalam memprediksi harga penutupan saham ISAT. Penelitian ini menggunakan data harga saham harian dari 28 Oktober 2022 hingga 27 Maret 2025, yang kemudian dianalisis untuk mengidentifikasi pola pergerakan harga saham tersebut. Berdasarkan hasil analisis, ditemukan bahwa kedua metode peramalan memiliki keunggulan dan keterbatasan masing-masing. Metode ARIMA lebih akurat dalam menangani data yang bersifat stasioner, sementara Exponential Smoothing lebih adaptif terhadap fluktuasi harga saham yang tidak menentu. Hasil penelitian ini diharapkan dapat memberikan wawasan bagi investor dalam memilih metode yang tepat untuk memprediksi pergerakan harga saham dengan volatilitas tinggi dan membantu pengambilan keputusan investasi yang lebih cerdas serta strategi manajemen risiko yang lebih efektif.

**Kata Kunci:** ARIMA; Exponential Smoothing; Peramalan Saham; Volatilitas Harga; ISAT

**Abstract**—The stock market is one of the most sought-after investment instruments due to its high profit potential. However, significant fluctuations in stock prices also bring considerable risks, which are influenced by various factors such as macroeconomic conditions, government policies, company financial reports, and market sentiment. Therefore, stock price analysis and forecasting have become important aspects for investors and market participants in making more accurate investment decisions. This research focuses on the stock of PT Indosat Ooredoo Hutchison Tbk (ISAT), which shows high volatility, particularly following a sharp decline in stock prices in late February 2025, which was suspected to be triggered by discrepancies between financial reports and analysts' expectations. The main objective of this study is to compare two commonly used time series forecasting methods, namely Autoregressive Integrated Moving Average (ARIMA) and Exponential Smoothing, in predicting the closing price of ISAT stock. This research uses daily stock price data from October 28, 2022 to March 27, 2025, which is then analyzed to identify patterns in the movement of stock prices. Based on the analysis, it was found that both forecasting methods have their respective strengths and limitations. The ARIMA method is more accurate in handling stationary data, while Exponential Smoothing is more adaptive to fluctuating stock prices. The results of this study are expected to provide insights for investors in selecting the appropriate method to predict stock price movements with high volatility and help make smarter investment decisions as well as more effective risk management strategies.

**Keywords:** ARIMA; Exponential Smoothing; Stock Forecasting; Price Volatility; ISAT

## 1. PENDAHULUAN

Perkembangan pasar modal di Indonesia mengalami pertumbuhan yang signifikan seiring meningkatnya partisipasi investor individu maupun institusional. Salah satu instrumen yang paling diminati adalah saham, karena dianggap memberikan keuntungan tinggi dibandingkan instrumen keuangan lainnya. Namun, di balik potensi keuntungan tersebut, terdapat risiko yang besar akibat fluktuasi harga saham yang tinggi. Volatilitas harga saham dapat dipengaruhi oleh berbagai faktor, seperti kondisi ekonomi makro, kebijakan moneter dan fiskal pemerintah, laporan keuangan perusahaan, serta sentimen pasar. Banyaknya investor lebih memilih saham resikonya kecil karena semakin tinggi volatilitas semakin besar tingkat ketidakpastian untuk mendapatkan return [1] [2].

Dalam menghadapi tantangan fluktuasi harga saham yang tinggi, pendekatan analisis berbasis data mining dan machine learning semakin banyak digunakan dalam berbagai sektor, termasuk sektor keuangan dan kesehatan. Misalnya, penelitian oleh Prasetyaningrum di tahun 2021 menggunakan algoritma Random Forest dalam memprediksi atribut karyawan terbaik dan terbukti mampu meningkatkan akurasi pengambilan keputusan berbasis data [3]. Penerapan machine learning juga digunakan dalam prediksi lama perawatan pasien COVID-19 di DIY [4], di mana Random Forest menunjukkan performa yang lebih baik dibanding metode lain seperti k-NN dan deep learning, menunjukkan relevansi algoritma ini dalam situasi dengan kompleksitas data tinggi. Lebih jauh, Prasetyaningrum di tahun 2024 dalam penelitian lainnya menekankan pentingnya pengelolaan data tak seimbang dalam konteks klasifikasi elemen gamifikasi perbankan digital, yang menggambarkan peran machine learning dalam memahami pola perilaku konsumen melalui pendekatan klasifikasi multi-metode [5]. Penggunaan machine learning seperti ini menjadi pendekatan penting dalam analisis deret waktu, termasuk untuk prediksi harga saham yang volatil.

Salah satu saham yang menunjukkan volatilitas signifikan dalam beberapa tahun terakhir adalah saham PT Indosat Ooredoo Hutchison Tbk (ISAT), sebuah perusahaan telekomunikasi besar yang terdaftar di Bursa Efek Indonesia. Menurut Ismaliah. 2024 penurunan total ekuitas PT. Indosat, Tbk disebabkan oleh modal perusahaan yang dipergunakan melebihi dari besarnya sumber modal yang telah didapatkan oleh perusahaan tersebut. [6], termasuk peristiwa signifikan pada 28 Februari 2025, ketika harga saham turun drastis dari Rp2.200,00 menjadi Rp1.480,00 per lembar dalam kurun waktu kurang dari tiga minggu. Penurunan ini diduga dipicu oleh ketidaksesuaian data laporan keuangan perusahaan dengan konsensus analis, yang kemudian memunculkan kepanikan di pasar. Peristiwa ini menunjukkan betapa pentingnya pengembangan metode prediksi harga saham yang akurat untuk membantu investor dalam mengambil keputusan berbasis data historis.

Beberapa penelitian sebelumnya telah mencoba membandingkan pemodelan dan memprediksi menggunakan berbagai pendekatan statistik dan komputasional. Penelitian yang dilakukan Zahrunnisa pada tahun 2021 dengan metode DES merupakan metode terbaik dalam peramalan data time series garis kemiskinan Provinsi Jawa Tengah [7]. Pada tahun 2023, Fahmuddin melakukan penelitian dengan membandingkan ARIMA dan Single Exponential Smoothing adalah metode terbaik untuk melakukan peramalan nilai ekspor kakao Indonesia adalah metode ARIMA [8]. Dalam penelitian lain Saragih S dan Sembiring P pada tahun 2022, berdasarkan pengolahan data yang telah dilakukan, metode Double Exponential Smoothing dari Brown memiliki waktu komputasi yang lebih cepat jika dibandingkan dengan metode ARIMA [9]. penelitian oleh Cahyantari N, Sumarjaya I, Widana I. (2021) Peramalan metode Seasonal ARIMA dirasa lebih tepat untuk meramalkan Jumlah Wisatawan Asing yang Datang ke Bali tahun 2020 daripada metode Winter's Exponential Smoothing [10].

Selain metode ARIMA dan teknik statistik lainnya, penerapan algoritma machine learning dan data mining kini menjadi tren utama dalam analisis bisnis dan keuangan. Studi oleh Wahyuningsih W dan Prasetyaningrum P di tahun 2023, memperlihatkan bagaimana algoritma FP-Growth digunakan secara efektif dalam menganalisis pola pembelian konsumen pada industri coffee shop [11]. Mereka mengembangkan paket penjualan berdasarkan asosiasi item yang memiliki nilai support dan confidence tinggi, yang pada akhirnya meningkatkan kepuasan dan loyalitas pelanggan. Pendekatan serupa dapat diterapkan dalam konteks prediksi harga saham dengan tujuan mengenali pola-pola transaksi historis yang berulang. Lebih lanjut, dalam studi terpisah oleh Prasetyaningrum P, Purwanto P, Rochim A. Tahun 2025 hasilnya menyatakan, kombinasi antara algoritma K-Means clustering dan berbagai classifier seperti SVM, Random Forest, hingga Logistic Regression digunakan untuk mengelompokkan dan memprediksi perilaku konsumen dalam aplikasi perbankan mobile yang gamified [12]. Temuan mereka menunjukkan bahwa klasifikasi berbasis SVM memberikan akurasi tertinggi dalam mengidentifikasi segmen pengguna dengan berbagai tingkat interaksi dan engagement. Penerapan pendekatan ini dalam pasar saham dapat memberikan keunggulan kompetitif dalam memprediksi respon pasar dan tren harga.

Kemajuan teknologi informasi dan teknik data mining telah menjadi katalisator dalam meningkatkan akurasi prediksi di berbagai sektor, termasuk sektor pendidikan dan bisnis. Windarti di tahun 2020, menunjukkan bahwa algoritma Multilayer Perceptron (MLP) memiliki akurasi tinggi dalam memprediksi kelulusan mahasiswa dengan tingkat akurasi mencapai 92,31% pada pengujian Percentage Split dan RMSE terendah dibandingkan dengan algoritma lain seperti Naïve Bayes, IBk, dan J48 [13]. Studi lainnya oleh Haspriyanti di tahun 2021, memanfaatkan metode K-Nearest Neighbor (KNN) untuk memprediksi layanan Indihome terlaris [14]. Hasil menunjukkan bahwa metode ini sangat efektif dalam mengidentifikasi preferensi pelanggan berdasarkan histori penjualan, dengan akurasi prediksi mencapai hampir 100%. Ini menunjukkan bahwa metode klasifikasi sederhana namun kuat seperti KNN dan MLP sangat berguna untuk prediksi berbasis data besar, termasuk dalam konteks harga saham.

Sementara itu Prasetyaningrum pada tahun 2023, mengkaji transformasi pelayanan pelanggan melalui implementasi e-CRM berbasis website [15], yang menyoroti pentingnya pemanfaatan teknologi digital untuk meningkatkan loyalitas pelanggan dan memperkuat hubungan pelanggan dalam kompetisi pasar yang ketat. Pendekatan ini memberikan inspirasi bagi penerapan teknologi serupa dalam pasar modal untuk mempertahankan investor dan meningkatkan engagement. Berdasarkan kajian tersebut, dapat disimpulkan bahwa model ARIMA tetap menjadi salah satu metode statistik yang andal dalam prediksi deret waktu finansial. Namun, dalam menghadapi volatilitas harga saham ISAT yang tidak beraturan, ternyata telah banyak penelitian yang membandingkan efektivitas model ARIMA dan Exponential Smoothing. Meskipun demikian, perbedaan pendekatan kedua metode tetap relevan untuk dianalisis lebih lanjut. ARIMA mengandalkan asumsi stasioneritas dan memerlukan transformasi data, sedangkan Exponential Smoothing lebih responsif terhadap perubahan tren jangka pendek tanpa memerlukan proses transformasi yang kompleks [9].

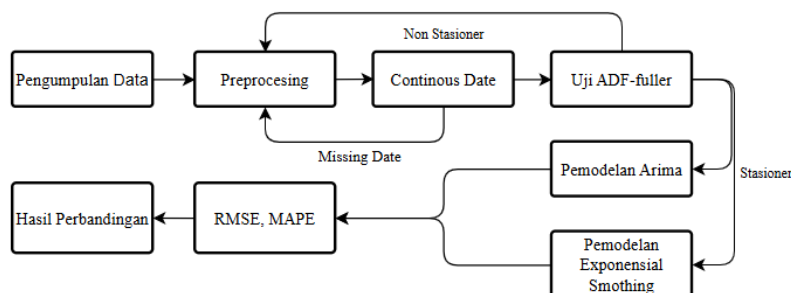
Meskipun telah ada penelitian yang membandingkan metode peramalan harga saham, masih terdapat kekurangan dalam hal analisis perbandingan yang mendalam antara ARIMA dan Exponential Smoothing, khususnya dalam konteks saham dengan volatilitas tinggi. Penelitian sebelumnya mungkin belum secara spesifik mengevaluasi efektivitas kedua metode ini dalam menangkap pola volatilitas yang terjadi pada saham tertentu, seperti ISAT. Pengujian ini bertujuan memberikan kontribusi pada literatur peramalan keuangan dengan membandingkan kedua metode tersebut dalam konteks peramalan harga penutupan saham dengan volatilitas tinggi. mengevaluasi apakah terdapat perbedaan hasil peramalan yang signifikan antara kedua model yang digunakan [16]. dan prediksi harga penutupan saham ISAT dengan membandingkan dua metode peramalan deret waktu, yaitu ARIMA dan Exponential Smoothing. Dalam penelitian ini metode ARIMA dan SES perlu dibandingkan untuk mencari metode peramalan yang baik dan tepat [17], diharapkan penelitian ini dapat memberikan kontribusi dalam bentuk model prediksi yang lebih

akurat dan relevan bagi investor serta pihak-pihak yang berkepentingan dalam dunia pasar modal. Selain itu, penelitian ini juga diharapkan mampu memberikan gambaran tentang efektivitas masing-masing metode dalam menangkap pola volatilitas yang terjadi pada saham dengan karakteristik serupa.

## 2. METODOLOGI PENELITIAN

### 2.1 Tahapan Penelitian

Pengujian ini dilakukan untuk menganalisis dan membandingkan performa metode ARIMA dan Exponential Smoothing[18][19] dalam memprediksi harga penutupan (close price) saham Indosat Ooredoo (ISAT). Tahapan penelitian ini meliputi lima langkah utama, yaitu: pengumpulan data, pra-pemrosesan data, pengujian stasioneritas, pemodelan menggunakan kedua metode, serta evaluasi hasil prediksi. Tahap pertama adalah pengumpulan data yang dilakukan melalui situs Investing.com. investing.com merupakan website gratis yang sering di jadikan referensi para brokersaham amupun analis saham untuk memberikan rekomen saham-saham yang sedang bagus untuk di investasikan atau ditradingkan[20]. Untuk memperjelas tahapan tersebut, ditampilkan dalam Gambar 1 berikut.



Gambar 1. Tahapan Penelitian

Diagram alur pada Gambar 1 menunjukkan bahwa setelah data dikumpulkan, dilakukan preprocessing sebelum analisis lanjutan. Penggunaan dua metode prediksi (ARIMA dan Exponential Smoothing) dilakukan secara paralel, dan hasil prediksi masing-masing metode diuji dan dibandingkan performanya.

### 2.2 Data collecting

Data yang dikumpulkan berupa harga penutupan saham harian dari PT Indosat Ooredoo Hutchison Tbk (kode saham: ISAT). Data dikumpulkan dalam format .csv dan dimuat ke dalam Python menggunakan pustaka pandas. Data yang digunakan memiliki cakupan periode 28 Oktober 2022 hingga 27 Maret 2025(860 data).

### 2.3 Preprocessing

Tahap kedua adalah pra-pemrosesan data, yaitu mengubah kolom tanggal menjadi tipe data datetime dan menjadikan tanggal sebagai indeks data. Dilakukan juga pengecekan frekuensi data menggunakan fungsi `pandas.infer_freq` [21], dan jika ditemukan ketidakkonsistenan dalam frekuensi tanggal, maka dilakukan penyesuaian frekuensi data menjadi harian menggunakan metode forward-fill (`asfreq('D', method='ffill')`)[21].

### 2.4 ADF Fuller

Tahap ketiga adalah pengujian stasioneritas data menggunakan uji Augmented Dickey-Fuller (ADF)[22]. Uji ini digunakan untuk mengidentifikasi apakah data memiliki sifat stasioner[23], yaitu mean dan varians konstan sepanjang waktu. Jika p-value dari uji ADF lebih besar dari 0.05 jika struktur stokastik dari timeseriestersebut mengalami perubahan sepanjang waktu (changeovertime), maka timeseriestersebut disebut time seriesnonstasioner[24] dan perlu dilakukan differencing. Persamaan 1 meampilkan rumus ADF fuller.

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_{i=1}^p \delta_i \Delta y_{t-i} + \varepsilon_t \quad (1)$$

Perubahan nilai suatu variabel pada waktu ke-t (dinyatakan sebagai  $\Delta y_t$ ) dipengaruhi oleh beberapa komponen: sebuah konstanta ( $\alpha$ ), tren waktu linear ( $\beta t$ ), nilai variabel tersebut pada periode sebelumnya ( $\gamma y_{t-1}$ ), serta jumlah perubahan nilai variabel pada beberapa periode sebelumnya (dituliskan dalam bentuk penjumlahan  $\sum$  dari  $i = 1$  hingga  $p$ , dengan koefisien  $\delta_i$  untuk setiap  $\Delta y_{t-i}$ ). Seluruhnya dilengkapi dengan error acak ( $\varepsilon_t$ ) sebagai gangguan residu dalam model.

### 2.5 Plot ACF, PACF dan Sensitifitas Model

Alpha ( $\alpha$ ): parameter smoothing level, yang mengontrol seberapa cepat model merespons perubahan level dalam data. Beta ( $\beta$ ): parameter smoothing tren, yang mengatur kepekaan model terhadap perubahan tren. Double Exponential Smoothing. Sedangkan model ARIMA dibangun dengan menentukan parameter ( $p, d, q$ ) berdasarkan hasil plot ACF dan PACF. Tahap kelima adalah evaluasi performa model. Evaluasi dilakukan dengan membagi data

menjadi dua bagian, yaitu data latih (hingga 1 Januari 2025) dan data uji (setelah 1 Januari 2025). Model di-train menggunakan data latih dan diuji terhadap data uji. Performa diukur menggunakan dua metrik: Root Mean Squared Error (RMSE) dan Mean Absolute Percentage Error (MAPE). Kedua metrik ini memberikan informasi seberapa besar kesalahan prediksi yang dihasilkan oleh model.

## 2.6 Evaluasi Model

Metode Autoregressive Integrated Moving Average (ARIMA) digunakan dalam penelitian ini karena kemampuannya dalam mengolah data deret waktu yang bersifat non-musiman. ARIMA merupakan model statistik yang memadukan tiga komponen utama, yakni autoregressive (AR), differencing (I), dan moving average (MA)[7]. Model ini diidentifikasi melalui tiga parameter, yaitu:

- p: menunjukkan tingkat autoregressive, yang menggambarkan hubungan antara nilai sekarang dengan nilai masa lalunya.
- d: menyatakan tingkat differencing yang diperlukan untuk membuat data menjadi stasioner.
- q: menyatakan tingkat moving average, yang merepresentasikan hubungan antara nilai saat ini dengan kesalahan acak pada periode sebelumnya. Berikut Persamaan 2 yang menjelaskan tentang rumus ARIMA.

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q} + \varepsilon_t \quad (2)$$

Model ARIMA (AutoRegressive Integrated Moving Average) menggambarkan hubungan antara nilai data saat ini  $y_t$  dengan sejumlah nilai masa lalu dari data itu sendiri ( $y_{t-1}$ ,  $y_{t-2}$ , ...,  $y_{t-p}$ ) dan kesalahan masa lalu ( $\varepsilon_{t-1}$ ,  $\varepsilon_{t-2}$ , ...,  $\varepsilon_{t-q}$ ), serta sebuah konstanta  $c$ . Nilai  $y_t$  dipengaruhi oleh kombinasi dari pengaruh data sebelumnya yang dikendalikan oleh parameter autoregressive  $\phi_1$ ,  $\phi_2$ , ...,  $\phi_p$ , dan pengaruh kesalahan sebelumnya yang diatur oleh parameter moving average  $\theta_1$ ,  $\theta_2$ , ...,  $\theta_q$ . Selain itu,  $\varepsilon_t$  adalah komponen kesalahan pada waktu  $t$ . Dengan demikian, model ARIMA memanfaatkan informasi dari data dan kesalahan masa lalu untuk memprediksi nilai data di masa depan.

Penelitian ini juga menggunakan pendekatan Exponential Smoothing[25], yang merupakan salah satu teknik peramalan klasik yang banyak digunakan dalam konteks bisnis dan keuangan. Metode ini memanfaatkan bobot eksponensial yang semakin menurun terhadap data historis seiring berjalannya waktu. Double Exponential Smoothing (DES). Berikut Persamaan 3 yang menjelaskan tentang rumus DES.

$$\begin{aligned} L_t &= \alpha y_t + (1 - \alpha)(L_t - 1 + T_t - 1) \\ T_t &= \beta(L_t - L_t - 1) + (1 - \beta)T_t - 1 \\ \widehat{y_{t+h}} &= L_t + hT_t \end{aligned} \quad (3)$$

Rumus double exponential smoothing digunakan untuk peramalan data dengan tren, di mana metode ini memperbarui perkiraan berdasarkan nilai historis dengan mempertimbangkan dua aspek utama: level (nilai dasar dari data) dan tren (perubahan dari waktu ke waktu). ( $L_t = \alpha y_t + (1 - \alpha)(L_{t-1} + T_{t-1})$ ): Persamaan ini memperbarui estimasi nilai dasar (level) dengan menggabungkan data aktual ( $y_t$ ) dan prediksi sebelumnya, dikontrol oleh parameter pelisiran ( $\alpha$ ). ( $T_t = \beta(L_t - L_{t-1}) + (1 - \beta)T_{t-1}$ ): Ini menghitung estimasi tren baru berdasarkan perubahan nilai level, dikontrol oleh parameter pelisiran ( $\beta$ ). ( $\widehat{y_{t+h}} = L_t + hT_t$ ): Rumus ini digunakan untuk meramalkan nilai di masa depan dengan menambahkan tren yang diperkirakan ke nilai level terbaru. Dengan metode ini, model tidak hanya memperhitungkan nilai saat ini, tetapi juga pola perubahannya, sehingga lebih akurat dalam meramalkan data yang memiliki tren naik atau turun.

Kedua metode memiliki keunggulan masing-masing: ARIMA unggul dalam akurasi untuk data stasioner dengan karakteristik non-musiman, sedangkan Exponential Smoothing cenderung lebih sederhana dan cepat dalam implementasi serta adaptif terhadap data yang fluktuatif [7]. Oleh karena itu, perbandingan keduanya diharapkan dapat memberikan wawasan lebih dalam mengenai performa prediksi harga saham berdasarkan pendekatan deret waktu. Evaluasi model dilakukan menggunakan rumus: Persamaan 4.

### 2.6.1 RMSE (Root Mean Square Error)

$$\{RMSE\} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \widehat{y}_i)^2} \quad (4)$$

RMSE adalah ukuran kesalahan prediksi yang sering digunakan untuk menilai akurasi model peramalan atau regresi[26]. Rumus RMSE ( $\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \widehat{y}_i)^2}$ ) mengukur rata-rata kesalahan antara nilai aktual ( $y_i$ ) dan nilai prediksi ( $\widehat{y}_i$ ) dalam bentuk kuadrat sebelum mengambil akar kuadratnya. Dengan demikian, RMSE memberikan gambaran tentang sejauh mana prediksi menyimpang dari nilai sebenarnya, dengan memberikan bobot lebih besar pada kesalahan yang lebih besar, sehingga cocok digunakan untuk menilai ketepatan model prediksi dalam satuan yang sama dengan data aslinya, Persamaan 05 menunjukan rumus MAPE.



## 2.6.2 MAPE (Mean Absolute Percentage Error)

$$MAPE = \left(100\% - \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \right) \quad (5)$$

MAPE adalah ukuran kesalahan prediksi yang dinyatakan dalam bentuk persentase[26]. Rumus MAPE ( $\frac{1}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{y_i} \times 100\%$ ) menghitung rata-rata kesalahan absolut dalam bentuk persentase dengan membandingkan selisih antara nilai aktual ( $y_i$ ) dan nilai prediksi ( $\hat{y}_i$ ) terhadap nilai aktualnya. Karena dinyatakan dalam persentase, MAPE memudahkan interpretasi kesalahan relatif dibandingkan dengan ukuran absolut, menjadikannya berguna untuk membandingkan performa berbagai model peramalan terlepas dari skala datanya.

## 3. HASIL DAN PEMBAHASAN

Penelitian ini bertujuan untuk membandingkan efektivitas dua metode peramalan yang sering digunakan dalam analisis data time series, yaitu ARIMA dan Exponential Smoothing, dalam memprediksi harga penutupan saham ISAT (Indosat Ooredoo).

### 3.1 Analisis Data

Data yang digunakan dalam penelitian ini diperoleh dari Investing.com dan mencakup harga saham ISAT selama periode tertentu dengan frekuensi harian. Setiap analisis yang dilakukan pada data harga saham ini bertujuan untuk mengidentifikasi pola dan hubungan yang dapat digunakan untuk memprediksi harga di masa depan. Data yang diambil adalah 860 row dengan column date, close.

**Tabel 1.** Min-Max Date

Date	Close
2022-11-28	1.481
2025-03-27	1.455

Tabel data min max Date pada Tabel 1 menunjukkan data deret waktu yang diperoleh Untuk keperluan pelatihan dan pengujian model, data deret waktu saham ISAT dibagi menjadi dua bagian berdasarkan tanggal. Data historis hingga tanggal 1 Januari 2025 digunakan sebagai data latih (training set : 775 data), sedangkan data mulai tanggal 2 Januari 2025 digunakan sebagai data uji (testing set: 85 data). Pembagian ini bertujuan untuk mengevaluasi kinerja model dalam memprediksi harga saham yang belum pernah dilihat sebelumnya, sehingga memberikan gambaran kemampuan generalisasi model dalam menghadapi data nyata. Pendekatan pembagian 90 % dan 10 % sejalan dengan praktik umum dalam pemodelan deret waktu, di mana urutan kronologis data harus dipertahankan guna menghindari data leakage yang dapat menyebabkan estimasi performa menjadi tidak akurat.

#### 3.1.1 Uji Stasioneritas dengan ADF Test


Salah satu tahapan yang sangat penting dalam analisis data time series adalah uji stasioneritas. Data time series yang tidak stasioner dapat menghasilkan model yang tidak akurat, karena banyak model time series, seperti ARIMA, mengasumsikan bahwa data adalah stasioner. Oleh karena itu, pengujian menggunakan Augmented Dickey-Fuller (ADF) Test dilakukan untuk mengevaluasi apakah data harga saham ISAT mengandung unit root yang menunjukkan bahwa data tersebut tidak stasioner. Hasil dari ADF test menunjukkan bahwa p-value yang lebih besar dari 0.05 mengindikasikan bahwa data tidak stasioner. Oleh karena itu, proses differencing dilakukan untuk membuat data menjadi stasioner, Berikut Hasil Uji ADF Fuller.

**Tabel 2** Uji ADF Fuller

Test Statistic:	-29.629
p-value:	0.0
Critical Values:	
1%	-3.4380757734945697
5%	-2.8649502975181314
10%	-2.5685859111876925

Tabel hasil Uji ADF Fuller pada Tabel 2 menunjukkan Nilai Test Statistic sebesar -29.6294 dalam uji Augmented Dickey-Fuller (ADF) Data deret waktu dalam penelitian ini menunjukkan kemampuan yang kuat dalam menolak hipotesis nol (null hypothesis), yang berarti bahwa data tersebut tidak memiliki akar unit dan bersifat stasioner. Hipotesis nol dalam uji Augmented Dickey-Fuller (ADF) menyatakan bahwa data mengandung akar unit, yang menandakan bahwa pola pergerakannya tidak stabil dan dapat mengalami tren atau perubahan seiring waktu. Namun, karena nilai Test Statistic jauh lebih kecil daripada nilai kritis pada tingkat signifikansi 1%, 5%, dan 10%, hipotesis nol dapat ditolak dengan tingkat keyakinan yang sangat tinggi. Dengan demikian, data close dalam penelitian

ini bersifat stasioner, yang berarti pola pergerakannya relatif stabil tanpa mengalami tren yang signifikan. Stasioneritas dalam data deret waktu sangat penting dalam peramalan dan analisis statistik, karena model seperti ARIMA atau DES dalam analisis prediksi time series. Berikut untuk grafik perubahan harga close saham harian ditunjukkan pada Gambar 2.

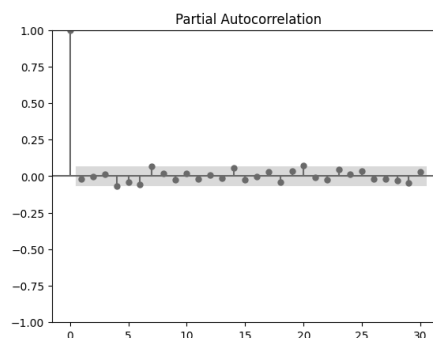


**Gambar 2.** Perubahan harga Close saham harian

Grafik pada Gambar 2 menunjukkan fluktuasi yang cukup signifikan, dengan beberapa lonjakan dan penurunan tajam selama periode yang diamati, dan grafik diatas sangat berguna untuk memahami volatilitas dan tren harga penutupan selama periode waktu tertentu. Dan berguna untuk menentukan metode analisis yang digunakan


### 3.2.1. Plot ACF dan PACF

Plot ACF digunakan untuk memahami korelasi antara nilai dalam suatu deret waktu dengan nilai sebelumnya (lagged values). Dari hasil yang diperoleh, terlihat bahwa nilai autokorelasi awal cukup tinggi dan secara bertahap menurun seiring bertambahnya lag. Pola ini menunjukkan adanya kemungkinan ketergantungan jangka panjang dalam data, yang dapat mengindikasikan komponen moving average (MA) dalam pemodelan deret waktu.



**Gambar 3.** Plot Pacf

Grafik plot pada Gambar 3 menunjukkan hasil grafik Partial Autocorrelation Function (PACF), terlihat bahwa hanya lag awal yang menunjukkan korelasi signifikan, sementara lag-lag berikutnya berada dalam interval kepercayaan, mengindikasikan bahwa data tidak memiliki ketergantungan jangka panjang yang kuat. Pola ini menunjukkan bahwa model Autoregressive (AR) dengan orde rendah dapat menjadi pendekatan yang sesuai untuk pemodelan deret waktu ini. Dengan memahami pola PACF ini, langkah selanjutnya dalam analisis deret waktu dapat difokuskan pada pemodelan dengan pendekatan ARIMA, memastikan bahwa data digunakan dengan metode yang optimal untuk peramalan atau analisis lebih lanjut.



**Gambar 4** Plot Acf

Grafik plot pada Gambar 4 menunjukkan hasil plot Partial Autocorrelation Function (PACF), terlihat bahwa hanya lag awal yang menunjukkan korelasi parsial yang signifikan, sedangkan lag-lag berikutnya berada dalam interval kepercayaan, menandakan bahwa hubungan dengan nilai sebelumnya melemah setelah beberapa periode. Pola ini mengindikasikan bahwa data memiliki sifat autoregresif dengan orde rendah, yang dapat digunakan dalam pemodelan deret waktu untuk menangkap pola ketergantungan jangka pendek. Analisis ini menjadi landasan penting dalam memastikan bahwa pemodelan yang digunakan sesuai dengan sifat dasar data yang dianalisis.

### 3.3. Sensitivitas Model Arima

Bagian ini membahas pengujian sensitivitas model ARIMA terhadap variasi parameter *autoregressive* ( $p$ ) dengan tetap menjaga nilai  $d$  (differencing) dan  $q$  (moving average) pada nol, yakni format model  $(p,0,0)$ . Pengujian ini penting untuk mengetahui bagaimana perubahan parameter  $p$  memengaruhi performa model terhadap prediksi harga saham ISAT.

Model ARIMA diuji pada lima konfigurasi berbeda:  $(0,0,0)$ ,  $(2,0,0)$ ,  $(4,0,0)$ ,  $(15,0,0)$ , dan  $(80,0,0)$ . Setiap model dievaluasi menggunakan dua metrik utama:

- RMSE (Root Mean Square Error): Mengukur kesalahan prediksi rata-rata model dalam satuan asli data.
- MAPE (Mean Absolute Percentage Error): Menunjukkan persentase kesalahan prediksi relatif terhadap nilai aktual.
- Berikut adalah hasil pengujian sensitivitas model:

**Tabel 3.** Sentivitas Model Arima

Konfigurasi ARIMA ( $p,0,0$ )	RMSE	MAPE
$(0,0,0)$	0.53393	0.25975
$(2,0,0)$	0.57135	0.28039
$(4,0,0)$	0.56354	0.27679
$(15,0,0)$	0.56034	0.27250
$(80,0,0)$	0.56034	0.27250

Sensitivitas pada Tabel 3 Menjukan Hasil Sensitivitas model Arima yang dilakukan percobaan analisis untuk mencari nilai RMSE dan MAPE terkecil dengan mengubah variasi parameter *autoregressive* ( $p$ ).

Analisis dan Interpretasi:

- Model ARIMA  $(0,0,0)$ : Model ini adalah baseline tanpa komponen *autoregressive*, *differencing*, maupun *moving average*. Menariknya, ia memberikan hasil RMSE dan MAPE yang cukup kompetitif dibanding model lain, menunjukkan bahwa data historis cukup menjelaskan pola tanpa perlu *autoregressive*.
- Peningkatan Nilai  $p$ : Ketika nilai  $p$  dinaikkan ke 2 dan 4, terjadi peningkatan pada nilai RMSE dan MAPE. Ini menunjukkan bahwa penambahan parameter AR justru memperburuk performa model, mungkin karena *overfitting* atau noise yang tidak relevan dimasukkan ke dalam prediksi.
- Model ARIMA  $(15,0,0)$  dan  $(80,0,0)$ : Meskipun secara teori penambahan lag ( $p$ ) dapat menangkap hubungan jangka panjang dalam data, pada kasus ini nilai RMSE dan MAPE tidak memperlihatkan perbaikan signifikan dibanding konfigurasi awal. Bahkan model  $(80,0,0)$  memberikan hasil identik dengan model  $(15,0,0)$ , yang kemungkinan besar disebabkan oleh redundansi informasi atau kestabilan pola pada lag tertentu.
- Kesimpulan Sementara: Sensitivitas model terhadap parameter  $p$  dalam kasus ini menunjukkan bahwa peningkatan nilai AR tidak serta-merta meningkatkan akurasi prediksi. Model  $(0,0,0)$  justru menjadi pilihan yang efisien dan cukup akurat, meskipun secara teoretis ia sangat sederhana.

Penemuan ini memperkuat pentingnya seleksi parameter berbasis evaluasi empiris, bukan hanya asumsi teoretis. Dalam praktiknya, model sederhana terkadang dapat mengalahkan model kompleks, terutama dalam kasus data yang tidak terlalu banyak noise atau tidak memiliki pola jangka panjang yang kuat.

### 3.4. Sensitivitas Model Double Exponansial Smothing

Model Double Exponential Smoothing (DES) adalah perluasan dari Simple Exponential Smoothing yang memperhitungkan tren dalam data deret waktu. Dalam konteks prediksi harga saham ISAT, model ini digunakan untuk menangkap pergerakan tren yang tidak bisa ditangani oleh model eksponensial sederhana. Evaluasi sensitivitas pada model ini dilakukan untuk melihat seberapa besar perubahan parameter *smoothing* mempengaruhi akurasi prediksi.

Parameter Kunci dalam Double Exponential Smoothing:

Double Exponential Smoothing mengandalkan dua parameter utama:

- Alpha ( $\alpha$ ): parameter *smoothing level*, yang mengontrol seberapa cepat model merespons perubahan level dalam data.
- Beta ( $\beta$ ): parameter *smoothing tren*, yang mengatur kepekaan model terhadap perubahan tren.

Dalam penelitian ini, parameter alpha dan beta disesuaikan menggunakan proses *grid search* otomatis dalam library *statsmodels* untuk menemukan kombinasi terbaik berdasarkan data latih. Evaluasi dilakukan dengan menghitung RMSE dan MAPE untuk mengukur kinerja prediksi.

**Tabel 4** Hasil RMSE dan MAPE penerapan Model Double Exponential Smoothing

Metode	RMSE	MAPE
Double Exponential Smoothing	0.18909	0.08178

Hasil sensitivitas DES pada Tabel 4 menunjukkan Hasil RMSE dan MAPE penerapan Model Double Exponential Smoothing (DES) menunjukkan sensitivitas yang sangat baik terhadap data harga saham ISAT, terutama karena kemampuannya dalam menangkap dan mengikuti pola tren yang ada. Salah satu keunggulan utama model ini adalah kemampuannya untuk merespons perubahan tren secara efisien, sebagaimana tercermin dari hasil prediksi yang hampir sejalan dengan data aktual. Ini menunjukkan bahwa DES sangat efektif dalam mengenali arah pergerakan harga saham dalam jangka pendek hingga menengah. Tidak seperti model ARIMA yang sangat tergantung pada pemilihan parameter lag, model DES memiliki tingkat stabilitas yang tinggi terhadap variasi parameter smoothing (alpha dan beta). Selama parameter-parameter tersebut berada dalam kisaran optimal, performa model tetap konsisten dan tidak mudah terganggu oleh noise data.

Selain itu, model DES juga adaptif terhadap kondisi volatilitas tinggi yang menjadi ciri khas saham ISAT. Meskipun data menunjukkan fluktuasi yang tajam, model ini tetap mampu memberikan prediksi yang akurat dan tidak terlalu sensitif terhadap perubahan ekstrem. Kemudahan dalam implementasi menjadi nilai tambah tersendiri; model ini tidak memerlukan proses transformasi untuk membuat data menjadi stasioner sebagaimana yang dibutuhkan oleh ARIMA. Proses pemodelannya pun lebih cepat dan efisien, dengan jumlah parameter yang lebih sedikit untuk disesuaikan. Hal ini menjadikannya sangat praktis digunakan dalam skenario bisnis yang memerlukan hasil cepat dan akurat.

Namun demikian, model ini tetap memiliki keterbatasan, terutama dalam menangani pola musiman. Karena Double Exponential Smoothing hanya memperhitungkan level dan tren tanpa komponen musiman, maka penggunaannya menjadi kurang efektif jika data mengandung pola musiman yang kuat dan berulang. Untuk kasus seperti ini, penggunaan model Holt-Winters atau Triple Exponential Smoothing akan lebih tepat guna. Meskipun begitu, untuk prediksi harga saham seperti ISAT yang tidak menunjukkan pola musiman yang dominan, DES tetap menjadi alternatif yang sangat layak dan kompetitif dibandingkan model lainnya.

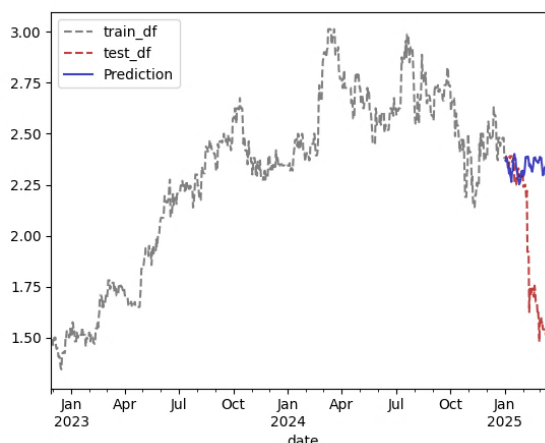
### 3.5. Penerapan Model Arima

Model ARIMA (AutoRegressive Integrated Moving Average) adalah salah satu model peramalan yang sangat populer dalam analisis data time series. ARIMA digunakan untuk memodelkan data yang tidak stasioner dengan menggabungkan tiga komponen utama: Autoregressive (AR), Integrated (I), dan Moving Average (MA). Pada penelitian ini, model ARIMA diterapkan dengan parameter (15,1,15), yang dipilih berdasarkan analisis ACF (Autocorrelation Function) dan PACF (Partial Autocorrelation Function). Parameter ini dipilih dengan tujuan untuk menangkap hubungan jangka panjang antara nilai-nilai masa lalu dari harga saham ISAT, yang dapat memberikan prediksi yang lebih akurat untuk harga di masa depan. Berikut untuk hasil penerapan model ARIMA.

**Tabel 5.** Hasil RMSE dan MAPE penerapan Model ARIMA

RMSE	MAPE
0.53393	0.25975

Hasil RMSE dan MAPE penerapan Model ARIMA pada Tabel 5 menunjukkan performa yang sangat baik pada data pelatihan, dengan Root Mean Squared Error (RMSE) sebesar 0.0413 dan Mean Absolute Percentage Error (MAPE) sebesar 0.0106, yang menunjukkan bahwa prediksi pada data pelatihan memiliki tingkat kesalahan yang sangat kecil. Namun, saat diuji pada data uji, RMSE meningkat menjadi 0.5942 dan MAPE naik menjadi 0.2925, menandakan bahwa terdapat perbedaan yang cukup signifikan antara hasil prediksi dan data aktual dalam periode uji.

**Gambar 5.** hasil Prediksi Arima



Grafik pada Gambar 5 Menunjukkan hasil pemodelan ARIMA, terlihat bahwa model berhasil menangkap pola pergerakan data historis dengan cukup baik. Grafik menunjukkan bahwa prediksi model (Prediction) mengikuti tren dari data pelatihan (train\_df) dan data uji (test\_df), meskipun terdapat beberapa perbedaan pada periode tertentu. Model ARIMA mampu mengidentifikasi struktur pola waktu dan menghasilkan estimasi yang mendekati nilai aktual dalam data uji. Namun, beberapa deviasi antara hasil prediksi dan data sebenarnya menunjukkan adanya faktor eksternal yang mungkin memengaruhi pergerakan data.

### 3.6. Penerapan Model Exponential Smoothing

Model Exponential Smoothing digunakan untuk menangani data yang memiliki komponen musiman dan tren. Dalam penelitian ini, model Double Exponential Smoothing diterapkan untuk menangani tren yang ada dalam data harga saham ISAT. Model ini berbeda dari ARIMA karena ia lebih sederhana dan digunakan untuk data yang memiliki pola musiman yang kuat dan konsisten. Double Exponential Smoothing digunakan dengan asumsi bahwa data harga saham ISAT memiliki komponen musiman yang tetap. Model ini menggunakan parameter seasonal='add' dan damped\_trend=False, yang menunjukkan bahwa model ini tidak mengasumsikan adanya pengaruh eksternal yang merubah pola musiman secara signifikan.


#### 3.6.1 Evaluasi Model Exponential Smoothing

Model Double Exponential Smoothing telah diterapkan untuk menganalisis data deret waktu, dengan hasil yang menunjukkan performa yang cukup baik. Dari grafik yang dihasilkan, prediksi model (Prediction) cenderung mengikuti pola dari data pelatihan (train\_df) dan data uji (test\_df), dengan beberapa deviasi pada periode tertentu. Hasil evaluasi untuk model Double Exponential Smoothing menunjukkan bahwa,

**Tabel 6.** Hasil Evaluasi Model Double Exponensial Smoothing

RMSE	MAPE
0.1890857435094599	0.08178587369193646

Hasil Evaluasi Model DES pada Tabel 6 menunjukkan RMSE (Root Mean Squared Error) sebesar 0.0583 pada data pelatihan, yang mengindikasikan bahwa tingkat kesalahan dalam prediksi relatif kecil. Sementara itu, nilai MAPE (Mean Absolute Percentage Error) sebesar 0.0097 pada data pelatihan memperkuat bahwa model dapat menangkap pola historis dengan baik. Ketika diuji pada data uji, RMSE meningkat menjadi 0.1891, dan MAPE menjadi 0.0818, yang menunjukkan bahwa model masih dapat memprediksi data dengan akurasi yang baik, meskipun terdapat sedikit peningkatan kesalahan dibandingkan dengan data pelatihan.



**Gambar 6.** Hasil Prediksi Pemodelan Double Exponensial Smoothing

Grafik pada Gambar 6 Hasil Prediksi Pemodelan Double Exponensial Smoothing menunjukkan bahwa Double Exponential Smoothing cukup efektif dalam menangkap pola tren dari data historis dan dapat digunakan untuk peramalan ke depan. Namun, perbedaan antara hasil prediksi dan nilai aktual dalam data uji mengindikasikan bahwa model dapat mengalami kesulitan dalam menangani pola yang lebih kompleks, sehingga kemungkinan pendekatan lain atau optimasi lebih lanjut diperlukan untuk meningkatkan performa prediksi. Jika diperlukan, langkah-langkah seperti penyesuaian parameter smoothing atau eksplorasi model lain seperti Triple Exponential Smoothing (Holt-Winters) dapat dipertimbangkan untuk menangkap pola musiman yang mungkin terdapat dalam data.

### 3.5 Pembahasan

Hasil evaluasi mengindikasikan bahwa Exponential Smoothing lebih unggul dalam menangkap pola kompleks harga saham, terutama karena kemampuannya mempertimbangkan keterkaitan nilai sebelumnya dalam periode yang lebih panjang. Ini menjadikannya pilihan yang lebih baik dibandingkan ARIMA, yang lebih sederhana dan cepat dalam implementasi tetapi kurang mampu menangkap variabilitas harga yang lebih kompleks.

ARIMA tetap memiliki keunggulan dalam situasi di mana pola harga relatif stabil atau mengikuti tren yang jelas, tetapi dalam konteks harga saham yang sering mengalami fluktuasi yang tidak sepenuhnya teratur, model Exponential Smoothing lebih sesuai. Meskipun demikian, pemilihan model bergantung pada tujuan analisis—apakah lebih menekankan akurasi prediksi jangka panjang atau efisiensi implementasi.

#### 4. KESIMPULAN

Berdasarkan hasil analisis dan evaluasi yang telah dilakukan terhadap prediksi harga penutupan saham Indosat Ooredoo Hutchison (ISAT), dapat disimpulkan bahwa pemodelan deret waktu menggunakan metode ARIMA dan Double Exponential Smoothing (DES) menunjukkan performa yang berbeda dalam menangani data saham dengan karakteristik fluktuatif. Model ARIMA yang diuji dengan berbagai konfigurasi parameter menunjukkan hasil yang cukup baik, terutama pada model (0,0,0) yang secara mengejutkan menghasilkan RMSE dan MAPE yang lebih rendah dibandingkan model dengan nilai lag lebih tinggi seperti (15,0,0) dan (80,0,0). Hal ini menunjukkan bahwa penambahan parameter autoregressive secara berlebihan tidak selalu meningkatkan akurasi prediksi dan bahkan bisa memperbesar kesalahan karena kemungkinan overfitting terhadap noise dalam data. Sementara itu, model Double Exponential Smoothing terbukti lebih unggul dalam hal akurasi dengan nilai RMSE 0.18908 dan MAPE, 0.08178 yang lebih rendah dibandingkan semua konfigurasi ARIMA dengan nilai RMSE 0.53393 dan MAPE 0.25975, menandakan kemampuannya dalam menangkap pola tren jangka pendek dengan lebih baik. Kendati demikian, penelitian ini juga memiliki beberapa keterbatasan yang perlu dicermati. Salah satu keterbatasan utama adalah bahwa analisis tidak mencakup pola musiman dalam data, sehingga model yang digunakan baik ARIMA maupun DES belum mencerminkan variasi musiman yang mungkin terdapat pada harga saham dalam jangka panjang. Selain itu, pemilihan parameter model dilakukan secara statis tanpa menggunakan pendekatan automasi atau optimasi hiperparameter yang lebih sistematis seperti grid search atau algoritma optimasi lainnya. Faktor eksternal yang memengaruhi harga saham seperti sentimen pasar, kondisi makroekonomi, atau berita fundamental perusahaan juga tidak dimasukkan ke dalam model, yang membuat prediksi hanya bergantung pada pola historis harga. Untuk penelitian selanjutnya, disarankan agar dilakukan pemodelan yang menggabungkan faktor eksternal dengan teknik machine learning yang lebih adaptif, seperti Long Short-Term Memory (LSTM) atau XGBoost, agar prediksi menjadi lebih akurat dan komprehensif. Selain itu, eksplorasi terhadap model musiman seperti SARIMA dan Holt-Winters dapat menjadi langkah lanjutan guna menangani pola musiman yang mungkin tidak teridentifikasi dalam penelitian ini.

#### REFERENCES

- [1] H. Rosyida, A. Firmansyah, dan S. B. Wicaksono, "Volatilitas Harga Saham: Leverage, Ukuran Perusahaan, Pertumbuhan Aset," *JAS (Jurnal Akuntansi Syariah)*, vol. 4, no. 2, hlm. 196–208, Des 2020, doi: 10.46367/jas.v4i2.256.
- [2] B. K. Meher, I. T. Hawaldar, L. Mohapatra, C. Spulbar, dan R. Birau, "The effects of environment, society and governance scores on investment returns and stock market volatility," *International Journal of Energy Economics and Policy*, vol. 10, no. 4, hlm. 234–239, 2020, doi: 10.32479/ijeep.9311.
- [3] P. T. Prasetyaningrum dan A. Y. Chandra, "Implementation Of Machine Learning To Determine The Best Employees Using Random Forest Method," *Network Security and Information System (IJCONSIST)*, vol. 2, no. 2, hlm. 53, 2021, doi: 10.33005/ijconsist.v2i02.43.
- [4] A. Supoyo, "Bianglala Informatika Analisis Data Mining Untuk Memprediksi Lama Perawatan Pasien Covid-19 Di DIY," *Bianglala Informatika*, vol. 10, no. 1, hlm. 2022, 2022, doi: 10.31294/bi.v10i1.11890.
- [5] P. T. Prasetyaningrum, P. Purwanto, dan A. F. Rochim, "Enhancing Element Game Classification: Effective Techniques for Handling Imbalanced Classes," *International Journal of Intelligent Engineering and Systems*, vol. 17, no. 1, hlm. 555–571, 2024, doi: 10.22266/ijies2024.0229.47.
- [6] H. Ismaliah, M. Rimawan, dan H. Muthiah, "Analisis DER Dan EPS Terhadap Harga Saham Pada PT. Indosat, Tbk," *eCo-Fin*, vol. 6, no. 3, Sep 2024, doi: 10.32877/ef.v6i3.1458.
- [7] A. Zahrunnisa, R. Dzakiya Nafalana, I. A. Rosyada, E. Widodo, dan P. S. Statistika, "Perbandingan Metode Exponential Smoothing dan ARIMA pada Peramalan Garis Kemiskinan Provinsi Jawa Tengah," *Jurnal Ilmiah Pendidikan Matematika, Matematika dan Statistika*, vol. 2, no. 3, 2021, doi: 10.46306/lb.v2i3.
- [8] M. S. Fahmuddin dan S. M. Sri Mustika, "Perbandingan Metode ARIMA dan Single Exponential Smoothing dalam Peramalan Nilai Ekspor Kakao Indonesia," *VARIANSI: Journal of Statistics and Its Application on Teaching and Research*, vol. 5, no. 3, hlm. 163–176, 2023, doi: 10.35580/variansium193.
- [9] S. M. Saragih dan P. Sembiring, "Analisis Perbandingan Metode ARIMA dan Double Exponential Smoothing dari Brown pada Peramalan Inflasi di Indonesia," *Journal of Fundamental Mathematics and Applications (JFMA)*, vol. 5, no. 2, hlm. 176–191, Nov 2022, doi: 10.14710/jfma.v5i2.15312.
- [10] N. P. A. D. Cahyantari, I. W. Sumarjaya, dan I. N. Widana, "Perbandingan Metode Seasonal ARIMA dan Metode Exponential Smoothing dalam Meramalkan Kunjungan Wisatawan Mancanegara ke Bali," *E-Jurnal Matematika*, vol. 10, no. 2, hlm. 59, Mei 2021, doi: 10.24843/mtk.2021.v10.i02.p321.
- [11] W. Wahyuningsih dan P. T. Prasetyaningrum, "Enhancing Sales Determination for Coffee Shop Packages through Associated Data Mining: Leveraging the FP-Growth Algorithm," *Journal of Information Systems and Informatics*, vol. 5, no. 2, hlm. 758–770, Mei 2023, doi: 10.51519/journalisi.v5i2.500.
- [12] P. T. Prasetyaningrum, P. Purwanto, dan A. F. Rochim, "Consumer Behavior Analysis in Gamified Mobile Banking: Clustering and Classifier Evaluation," *Online) Journal of System and Management Sciences*, vol. 15, no. 2, hlm. 290–308, 2025, doi: 10.33168/JSMS.2025.0218.



- [13] M. Windarti dan P. T. Prasetyaningrum, “Prediction Analysis Student Graduate Using Multilayer Perceptron,” *International Conference on Online and Blended Learning*, vol. 440, 2020, doi: 10.2991/assehr.k.200521.011.
- [14] A. U. Haspriyanti dan P. W. Prasetyaningrum, “Penerapan Data Mining Untuk Prediksi Layanan Produk Indihome Menggunakan Metode K-Nearest Neighbor,” *JISAI*, vol. 1, no. 2, 2021, doi: 10.26486/jisai.v1i2.17.
- [15] P. T. Prasetyaningrum, A. R. Wicaksono, dan H. Nurrofiq, “Transformasi pelayanan pelanggan: Implementasi e-CRM pada bisnis teh Nusantara berbasis website,” *Technologia: Jurnal Ilmiah*, vol. 14, no. 4, hlm. 368, Okt 2023, doi: 10.31602/tji.v14i4.12157.
- [16] Y. L. A. A. S. C. E. W. Agustini Tripena1, “Perbandingan metode Pemulusan Eksponensial Ganda Holt dan Metode Arima Box-Jenkins,” *Jurnal Elektro Luceat JELC*, Vol 7, No 2, 2021, doi: 10.32531/jelekn.v7i2.404.
- [17] A. A. Mubarakah, S. K. Dini, dan R. Artikel, “Perbandingan Metode Arima Dan Single Exponential Smoothing Dalam Peramalan Jumlah Peserta Keluarga Berencana Baru Di Kota Yogyakarta P-ISSN E-ISSN,” *Emerging Statistics and Data Science Journal*, vol. 1, no. 1, 2023, doi: 10.20885/esds.vol1.iss.1.art8.
- [18] J. Homepage dkk., “Research in the Mathematical and Natural Sciences Pemilihan Metode Optimal Untuk Prediksi Angka Kemiskinan di Provinsi Gorontalo: Perbandingan Double Exponential Smoothing dan Bayesian Structural Time Series,” *Res. Math. Nat. Sci.*, vol. 4, no. 1, hlm. 74–89, 2025, doi: 10.55657/rmns.v4i1.202.
- [19] M. Brilliant, I. A. Nurhasanah, dan H. Oktaria, “Perbandingan Metode Deep Learning Recurrent Neural Networks, ARIMA dan Holt-Winters Exponential Smoothing dalam Prediksi Pola Transaksi Pelanggan,” *Journal of Software Engineering and Technology*, vol. 1, no 1, 2021, doi: 10.69769/seat.v1i1.18.
- [20] F. Africano dan P. Negeri Sriwijaya afrizawati, “Pelatihan Sosialisasi Digital Saham dan Grafik Investing pada Majelis Dikdasmen Kajang Bayan,” *JPKM*, vol. 2, no 1, 2023
- [21] W. MCKINNEY, *Python for Data Analysis: Data Wrangling with pandas, NumPy, and Jupyter*, 3 (2023). “O’Reilly Media, Inc.,” 2022.
- [22] T. Mahgoub Mohamed, “Forecasting of Monthly Flow for the White Nile River (South Sudan),” *American Journal of Water Science and Engineering*, vol. 7, no. 3, hlm. 103, 2021, doi: 10.11648/j.ajwse.20210703.12.
- [23] F. Dhiya Ulhaq dkk., “Analisis Forecasting Harga Kopi Robusta, Arabika, dan Kakao Indonesia Periode 2024-2026 Model ARIMA,” *Jurnal Penelitian Nusantara*, vol. 1, no 1, hlm. 136–148, 2025, doi: 10.59435/menulis.v1i3.84.
- [24] A. V. Dalimunthe, “Pemodelan Jumlah Pengguna Metode Kontrasepsi Jangka Panjang (MKJP) di Provinsi Bengkulu Menggunakan Metode Arima dan Prophet,” *Journal of Mathematics and its Application*, vol. 3, no. 2, 2024, doi: 10.33369/diophantine.v3i2.38539.
- [25] G. Woo, C. Liu, D. Sahoo, A. Kumar, dan S. Hoi, “ETSformer: Exponential smoothing transformers for time-series forecasting,” 2022. doi: <https://doi.org/10.48550/arXiv.2202.01381>.
- [26] Trivusi, “Perbedaan MAE, MSE, RMSE, dan MAPE pada Data Science,” *Trivusi*. <https://www.trivusi.web.id/2023/03/perbedaan-mae-mse-rmse-dan-mape.html>, 2023.