

Prediksi Harga Komoditas Pangan Menggunakan Algoritma Long Short-Term Memory (LSTM)

Rizki Mugi Setya Adi, Sudianto*

Fakultas Informatika, Program Studi Teknik Informatika, Institut Teknologi Telkom Purwokerto, Banyumas, Indonesia

Email: ¹20102156@ittelkom-pwt.ac.id, ^{2,*}sudianto@ittelkom-pwt.ac.id

Email Penulis Korespondensi: sudianto@ittelkom-pwt.ac.id

Submitted: 01/09/2022; Accepted: 24/09/2022; Published: 30/09/2022

Abstrak—Pangan merupakan kebutuhan pokok bagi keberlangsungan hidup manusia. Adanya pangan, dipengaruhi oleh produksi dan harga jual. Permasalahan yang ada, produsen pangan merugi dengan dinamisnya harga jual. Selain itu, harga jual yang murah tidak sepadan dengan biaya produksi yang telah dihabiskan, khususnya produsen pangan pada komoditas pertanian yaitu petani lokal. Petani lokal merugi karena tidak mengetahui harga komoditas saat menjual hasil pertaniannya. Selain itu, permainan tengkulak yang menyebabkan petani lokal menjual hasil panennya dengan harga rendah. Sehingga dari permasalahan yang ada, diperlukan prediksi harga komoditi untuk membantu petani mengetahui harga komoditi sebelum menjual hasil pertaniannya ke Pasar. Tujuan dari penelitian ini yaitu melakukan prediksi harga komoditas pangan khususnya di Banyumas, agar petani lokal dapat mengetahui harga komoditas sebelum dijual ke Pasar. Metode Deep Learning yang digunakan yaitu Long Short-Term Memory (LSTM) yang mampu mengingat kumpulan informasi yang telah disimpan dalam jangka waktu panjang dengan data *time series*. Hasil yang diperoleh, model mampu melakukan prediksi harga komoditas pangan. Sementara itu, model prediksi dengan *epoch* 50 menunjukkan Root Mean Squared Error (RMSE) terendah dengan nilai 79.19%.

Kata Kunci: Harga; Kecerdasan Buatan; LSTM; Pangan; Prediksi

Abstract—Food is a basic need for human survival. The existence of food is influenced by production and selling prices. The problem that exists is that food producers lose out with the dynamics of selling prices. In addition, the low selling price is not commensurate with the production costs that have been spent, especially for food producers in agricultural commodities, namely local farmers. Local farmers lose money because they do not know the price of commodities when selling their agricultural products. In addition, the game of intermediaries causes local farmers to sell their crops at low prices. So from the existing problems, it is necessary to predict commodity prices to help farmers determine the commodity prices before selling their agricultural products to the market. This study aims to predict the price of food commodities, especially in Banyumas, so that local farmers can find the price of commodities before they are sold to the market. The Deep Learning method used is Long Short-Term Memory (LSTM), which can remember a collection of information that has been stored for a long time with time series data. The results obtained, the model can predict food commodity prices. Meanwhile, the prediction model with epoch 50 shows the lowest Root Mean Squared Error (RMSE) with a value of 79.19%.

Keywords: Artificial Intelligence; Food; LSTM; Prediction; Price

1. PENDAHULUAN

Banyumas merupakan salah satu daerah di provinsi Jawa Tengah yang memiliki potensi yang besar dalam sektor pertanian. Pertanian di Banyumas dapat dijadikan sebagai sektor strategis dalam pembangunan dan peningkatan perekonomian daerah. Berdasarkan data Badan Statistik (BPS) Jawa Tengah, pada tahun 2020 produksi padi di Kabupaten Banyumas mencapai 290.756 ton, dengan produksi beras sebesar 166.341 ton, dan tahun 2021 produksi padi 296.383 ton dengan produksi beras sebesar 169.559 ton [1], sehingga pertanian di Banyumas memiliki potensi untuk berkembang pesat kedepannya [2]. Permasalahan yang ada, nilai Tukar Petani (NTP) Jawa Tengah Desember 2020 sebesar 101,49 atau turun -0,69% dibanding NTP bulan sebelumnya sebesar 102,19. Penurunan NTP disebabkan Indeks Harga yang diterima Petani (It) mengalami penurunan -0,27% lebih rendah dibanding kenaikan indeks harga yang dibayar petani (Ib) sebesar 0,42 persen [3]. Sehingga kejadian ini menyebabkan harga jual hasil panen di wilayah Banyumas tidak sepadan dengan biaya produksi yang dihabiskan.

Sementara itu, permainan tengkulak terhadap monopoli harga kepada petani yang mengakibatkan petani merugi, karena petani menjual hasil panennya dengan harga rendah. Hal ini disebabkan petani kurangnya informasi dan pengetahuan tentang harga komoditi terkini. Bahkan berbagai transaksi penting petani dilakukan secara tradisional seperti menjual hasil panennya kepada tengkulak / agen, sehingga tidak jarang petani dirugikan, menjadi obyek para pedagang yang memiliki peralatan dan jaringan yang lebih baik dan luas. Akibatnya, sebagian besar petani merugi. Bukan hanya itu saja, dalam penjualan komoditi pertanian, ternyata rantai yang terlalu panjang hanya menguntungkan tengkulak/agen tetapi merugikan petani dikarenakan harga yang tidak sesuai dengan ekspektasi petani. Selain itu, lemahnya posisi tawar petani menyebabkan rendahnya harga hasil panen pada komoditi di tingkat petani.

Dari permasalahan yang ada, penelitian ini menawarkan solusi untuk melakukan prediksi harga komoditi. Hal ini menjadi penting untuk membantu petani mengetahui harga komoditi sebelum menjual hasil pertaniannya ke Pasar, dan juga membantu petani lokal untuk meminimalisir rantai transaksi perdagangan. Prediksi harga komoditi dilakukan pada hasil pertanian di wilayah Banyumas menggunakan algoritme Deep Learning yaitu Long Short-Term Memory (LSTM). Penggunaan Deep Learning pada sistem rekomendasi lebih sesuai, dimana salah algoritme Deep Learning mampu bekerja dengan data yang besar. Metode Long Short-Term Memory (LSTM) juga merupakan subkelas dari Deep Learning dan termasuk dari salah satu algoritme yang dikembangkan berdasarkan algoritme Recurrent Neural

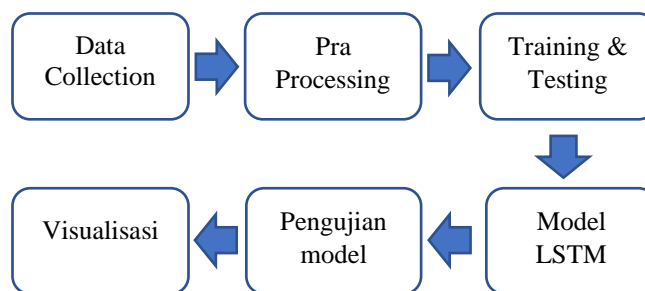
Network (RNN), dan dapat digunakan untuk mengekstrak informasi dari data. Deep Learning dapat melakukan klasifikasi berupa citra teks [4] maupun citra [5]. Selain itu, LSTM mampu mengingat kumpulan informasi yang telah disimpan dalam jangka waktu panjang.

Pada penelitian sebelumnya, pendekatan Deep Learning dalam melakukan prediksi telah banyak dilakukan seperti melakukan prediksi harga ponsel dengan Random Forest [6], Prediksi mata uang Bitcoin menggunakan LSTM dan sentiment analisis pada Sosial Media [7], *Price movement prediction of cryptocurrencies* menggunakan sentiment analysis and Machine Learning [8], Prediksi harga cryptocurrency menggunakan algoritme LSTM [9], Prediksi harga minyak mentah menggunakan Jaringan Syaraf Tiruan (JST) [10], Prediksi belanja pemerintah Indonesia menggunakan Long Short-Term Memory (LSTM) [11], Prediksi penggunaan energi listrik pada rumah hunian menggunakan Long Short-Term Memory [12]. Namun pada penelitian ini, prediksi dilakukan pada komoditas pangan dari hasil pertanian menggunakan algoritme LSTM.

Oleh karena itu, tujuan dari penelitian ini yaitu melakukan prediksi harga komoditi pangan menggunakan LSTM. Komoditi pangan yang dipilih yaitu komoditi beras dan jagung. Karena kedua komoditi ini menjadi komoditi unggulan di Banyumas. Selain itu, beberapa skenario dilakukan untuk memperoleh model yang maksimum.

2. METODOLOGI PENELITIAN

Penelitian ini dirancang berdasarkan beberapa proses: (1) *Data Collection*; (2) *praprocessing data*; (3) pembuatan model LSTMS; (4) pengujian model; (5) visualisasi. Detail alir dari penelitian ini dapat dilihat pada Gambar 1.



Gambar 1. Alir penelitian

Pada Gambar 1. pengumpulan data dilakukan pada tahun 2017 hingga 2022. Kemudian dilakukan praproses dengan melakukan normalisasi. Setelah itu, data dibagi menjadi data *training* dan *testing* untuk membangun model prediksi menggunakan LSTM. Terakhir, model LSTM yang optimal akan digunakan untuk melakukan prediksi harga komoditi.

2.1 Data Collection

Data yang digunakan adalah data harga beras medium di Banyumas, dimana data yang diambil difokuskan pada harga di Pasar tradisional di Banyumas yaitu Pasar Wage dan Pasar Manis. Data diambil dari website <https://hargajateng.org/> dari rentang waktu Januari 2017 hingga Juni 2022. Kemudian data dikumpulkan secara manual dan dijadikan satu ke dalam file Excel.

2.2 Praprocessing Data


Tujuan praprocessing data dilakukan untuk memastikan bahwa data yang tersedia berupa *time series*. Dari data yang tersedia, terdapat nilai data yang hilang atau kosong (*missing value*). Sehingga treatment ini dilakukan sebagai langkah untuk membentuk data time series. Nilai data yang hilang (*missing data*) pada penelitian ini dilakukan dengan mencari nilai rata-rata perbulan dari harga beras. Kemudian nilai rata-rata diisikan pada bagian yang kosong. Misal rata-rata bulan Januari Rp.10.000 maka untuk nilai yang hilang pada bulan Januari diisi dengan nilai rata-rata bulannya yaitu Rp.10.000. Selanjutnya data yang telah kosong yang telah terisi ditampilkan grafik dataset time series untuk melihat kondisi fluktuasi harga selama lima tahun terakhir.

Selain itu, praprocessing juga melakukan normalisasi dataset. Pada penelitian ini, normalisasi menggunakan min-max dengan batas range nilainya dari 0 sampai 1. Normalisasi min-max dilakukan untuk meminimalisasi atau menghindari nilai yang rentangnya besar mendominasi nilai yang rentangnya kecil. Normalisasi min-max pada penelitian ini menggunakan library python Scikit-learn MinMaxScaler.

2.3 Algoritme Long Short Term-Memory (LSTM)

Long Short Term-Memory (LSTM) merupakan turunan dari arsitektur *Recurrent Neural Network* (RNN) yang dibuat untuk mengatasi permasalahan mengatasi *vanishing gradien* yang sering terjadi pada RNN [10]. Metode *Long Short-Term Memory* (LSTM) merupakan sub kelas dari *Deep Learning* dan termasuk dari salah satu algoritme yang dikembangkan berdasarkan algoritme *Recurrent Neural Network* (RNN), dan dapat digunakan untuk klasifikasi dan mengekstrak informasi dari data [13]–[15].

Pada penelitian ini, pemodelan LSTM dilakukan dengan tujuan untuk mendapatkan model yang dapat memprediksi harga beras di Pasar Manis dan Pasar Wage, Banyumas. Proses pemodelan dan pengujian prediksi dilakukan dengan menggunakan bahasa pemrograman Python, dan menggunakan *framework* Keras dengan Tensorflow. Kemudian beberapa pustaka Python seperti Scikit-learn, Pandas, Matplotlib, Numpy, dan Seaborn.



Gambar 2. Struktur LSTM

Pada Gambar 2. inputan LSTM dimulai melalui komponen *forget gate* (f_t). Pada bagian ini informasi yang tidak dibutuhkan akan dihilangkan menggunakan fungsi sigmoid. Setelah itu membentuk kandidat vector baru menggunakan fungsi aktivasi tanh yang ditambahkan pada bagian *cell state*. Terakhir, *output gate* dihasilkan dari perkalian sigmoid dan nilai output tanh, dalam menghitung LSTM dapat menggunakan Formula 1 dan Formula 2.

$$o_t = \sigma(W_o * [h_{t-1}, x_t] + b_o) \quad (1)$$

$$h_t = o_t * \tanh(c_t) \quad (2)$$

Selanjutnya, pada penelitian ini untuk memperoleh model yang mampu bekerja dengan baik, dilakukan beberapa skenario nilai *epoch* yang berbeda, yaitu *epoch* 50, 100, dan 150. Kemudian pembagian *training* dan *testing* dilakukan *split* secara *random* 80:20 [16], [17].

2.4 Root Mean Squared Error (RMSE)

RMSE merupakan pengukuran dengan menghitung perbedaan nilai dari prediksi sebuah model sebagai estimasi nilai observasi. RMSE menghasilkan akar kuadrat Mean Square Error. Estimasi keakuratan model ditandai dengan nilai RMSE yang kecil. Sehingga semakin kecil nilai RMSE maka semakin akurat model yang didapatkan [18].

Dalam menghitung RMSE, nilai actual dan peramalan dikuadratkan dan dijumlahkan keseluruhan hasil. Kemudian dibagi dengan banyaknya data, dan dihitung Kembali nilai dari akadr kuadratnya. Perhitungan untuk memperoleh RMSE menggunakan Formula 3.

$$RMSE = \sqrt{\frac{\sum_{t=1}^n (A_t - F_t)^2}{n}} \quad (3)$$

Dimana:

A_t = Nilai data Aktual

F_t = Nilai hasil peramalan

N = banyaknya data

\sum = *Summation* (Jumlahkan keseluruhan nilai)

3. HASIL DAN PEMBAHASAN

3.1 Data Eksploratif

Data eksploratif dilakukan untuk memahami pola data sebelum dilakukan *treatmen* lebih lanjut. Pada penelitian ini, data yang telah terkumpul dilakukan visualisasi berupa rangkain data time series dari kejadian harga jual komoditi. Namun, dalam menyusun rangkaian data time series, terdapat juga kendala pada harga yang disebabkan *missing values* karena tidak adanya data. Sehingga dilakukan proses pembenahan *missing values* dengan menghitung rerata kejadian pada setiap bulannya dari harga komoditi.

Hasil dari proses penanganan *missing values* dapat dilihat pada Tabel 1 dan Tabel 2. Pada Tabel 1 dan 2, *sample* penanganan *missing values* dilakukan perhitungan rerata dari masing-masing bulan pada tiap tahunnya. Maka dari data yang kosong, akan diganti nilainya dengan nilai rerata pada bulan atau hari yang sama.

Tabel 1. Hasil penanganan *missing values* pada data Pasar Manis


Tahun	Bulan	Hasil Praprocessing
2017	Januari	8579
2018	Januari	12005

2019	Januari	10182
2020	Januari	10000
2021	Januari	10000
2022	Januari	10382

Tabel 2. Hasil penanganan *missing values* pada data Pasar Wage

Tahun	Bulan	Hasil Praprocessing
2017	Januari	8500
2018	Januari	11868
2019	Januari	9873
2020	Januari	9500
2021	Januari	9500
2022	Januari	10382

Selanjutnya, data *time series* yang telah tersedia di visualisasikan seperti pada Gambar 3. Hal ini dilakukan untuk mengetahui pola harga pada kurun waktu lima tahun terakhir. Pada Gambar 3, grafik harga komoditi beras, relative fluktuatif dengan harga jual dikisar 9,500 hingga 10,500 di Pasar Manis, sedangkan harga jual 9,000 hingga 10,000 di Pasar Wage. Meskipun diantara kedua pasar terdapat harga jual yang melonjak pada harga jual 12,000 pada tahun 2018.

**Gambar 3.** Grafik harga beras pada Pasar Manis dan Pasar Wage 2017 hingga Juni 2022

Tahap selanjutnya yaitu melakukan normalisasi. Normalisasi dilakukan untuk meminimalisasi nilai yang rentangnya besar mendominasi nilai yang rentangnya kecil. Normalisasi menggunakan min-max dengan batas range nilainya dari 0 sampai 1. Hal ini bertujuan agar data mudah diproses dan mengurangi redundansi. *Sample* dalam melakukan normalisasi seperti pada Tabel 3 dan Tabel 4. Kemudian visualisasi hasil normalisasi dapat dilihat pada Gambar 4.

Tabel 3. Hasil normalisasi dataset pada Pasar Manis

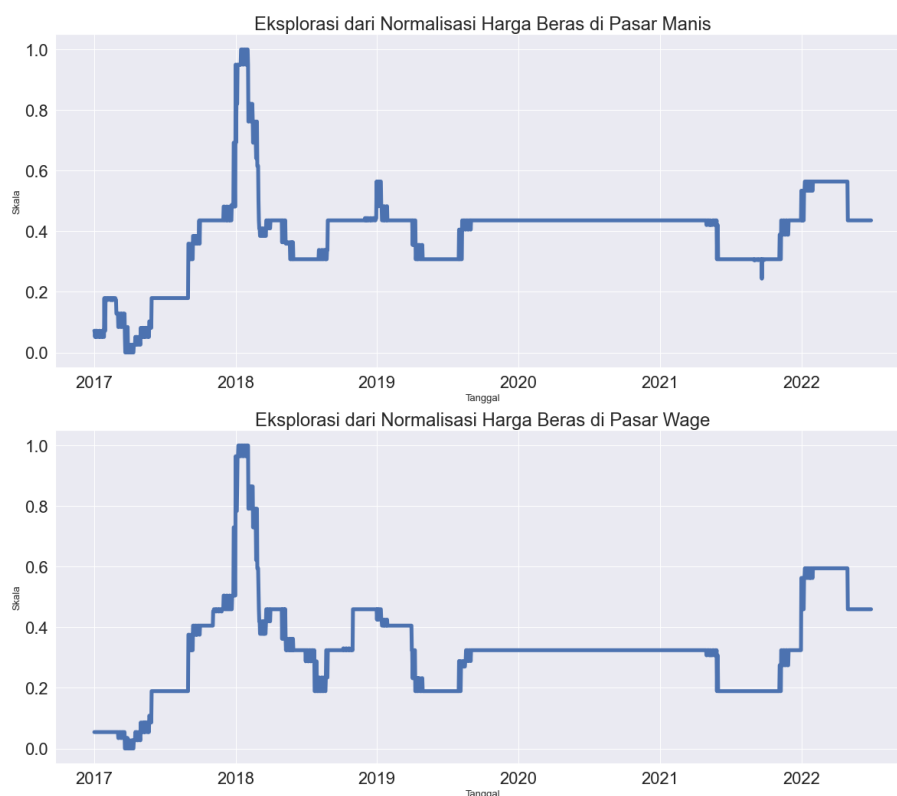
Tanggal	Data Aktual	Data normalisasi
2017-01-01	8579	0.071538
2017-01-02	8579	0.071538
2017-01-03	8500	0.051282
2017-01-01	8579	0.054054
2017-01-02	8500	0.071538
2017-01-03	8500	0.054054

Tabel 4. Hasil normalisasi dataset pada Pasar Wage

Tanggal	Data Aktual	Data normalisasi
2017-01-01	8500	0.054054
2017-01-02	8500	0.054054
2017-01-03	8500	0.054054
2017-01-01	8500	0.054054
2017-01-02	8500	0.054054
2017-01-03	8500	0.054054

Pada Gambar 4. merupakan hasil normalisasi dari kedua pasar, yaitu di Pasar Manis dan Pasar Wage. Normalisasi ditunjukkan dengan nilai fluktuatif berkisar pada angka 0 hingga 1. Pada data normalisasi Pasar Manis rerata 0,3 hingga 0,5. Sedangkan pada Pasar Wage rerata 0,2 hingga 0,4.

Visualisasi pada data Gambar 3 dan Gambar 4 memiliki pola yang sama, hal ini menunjukkan normalisasi tidak merubah pola, namun lebih mempermudah dalam proses identifikasi. Karena data normalisasi dibutuhkan untuk pembelajaran mesin atau melatih data dalam membangun model dengan algoritme LSTM.

**Gambar 4.** Grafik normalisasi harga pada Pasar Manis dan Pasar Wage 2017 hingga Juni 2022

3.2 Prediksi Harga dengan LSTM

Pada penelitian ini, prediksi harga dilakukan berdasarkan hasil dari model yang optimal. Pembuatan model dilakukan dengan beberapa skenario dan parameter. Skenario yang dilakukan yaitu membagi nilai *epoch* dengan tiga skenario; 50 *epoch*, 100 *epoch* dan 150 *epoch*. Hal ini dilakukan untuk memperoleh model yang optimal. Kemudian untuk parameter yang digunakan dalam membangun model prediksi yaitu parameter arsitektur, fungsi aktivasi dan *dropout rate* sesuai pada Tabel 5.

Tabel 5. Parameter yang digunakan dalam membangun model LSTM

Parameter	Spesifikasi
Arsitektur	1 LSTM layer dengan 75-unit Neuron & 1 Dense layer
Fungsi aktivasi	Tanh
Dropout rate	0.05
Optimizer	Adam

Berdasarkan tiga skenario, diperoleh hasil RMSE pada Pasar Manis masing-masing berurutan (*epoch* 50 hingga 150) 79.192; 80.680 dan 79.285. Sedangkan pada Pasar Manis masing-masing berurutan (*epoch* 50 hingga 150) yaitu 87.486; 91.191 dan 90.363. Dari kedua data yang telah dilakukan *training* dan *testing*, yaitu di Pasar Manis dan Pasar Wage *epoch* 50 memperoleh hasil RMSE lebih kecil dan optimal. Sehingga, model LSTM yang dipilih untuk


melakukan prediksi harga pangan yaitu model LSTM dengan *epoch* 50. Detail hasil RMSE dari kedua data pasar dapat dilihat pada Tabel 6. dan Tabel 7. Kemudian untuk visualisasi grafik dapat dilihat pada Gambar 5, Gambar 6 dan Gambar 7.

Tabel 6. Hasil RMSE Pasar Manis


Neuron	Epoch	RMSE
75	50	79.192
75	100	80.680
75	150	79.285

Tabel 7. Hasil RMSE Pasar Wage

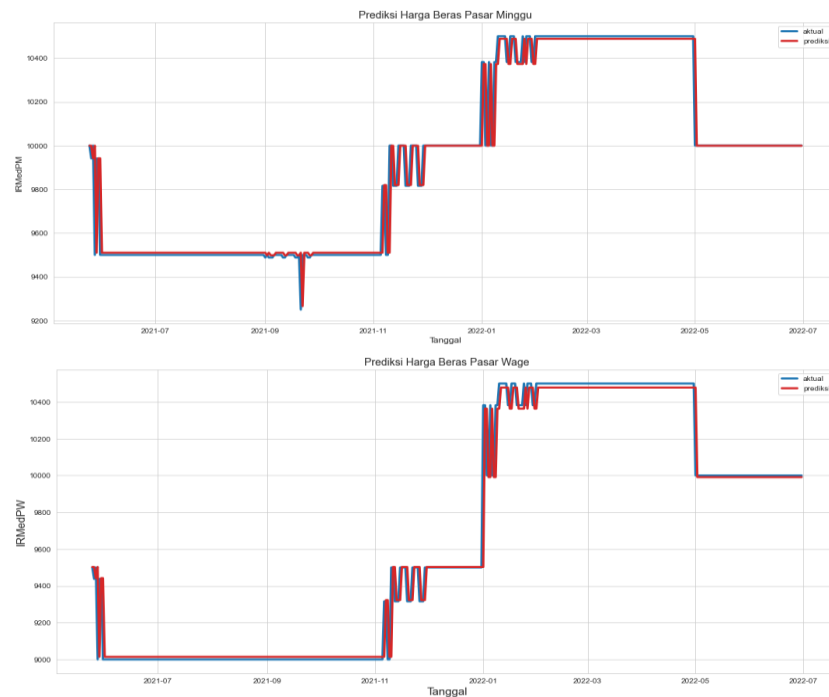
Neuron	Epoch	RMSE
75	50	87.486
75	100	91.191
75	150	90.363



Gambar 5. Grafik pengujian prediksi harga di Pasar Manis dan Pasar Wage dengan *epoch* 50




Gambar 6. Grafik pengujian prediksi harga di Pasar Manis dan Pasar Wage dengan *epoch* 100




Gambar 7. Grafik pengujian prediksi harga di Pasar Manis dan Pasar Wage dengan *epoch* 150

Selanjutnya, dari model LSTM *epoch* 50 dilakukan prediksi harga pada bulan September 2022. Berdasarkan hasil prediksi harga pada satu bulan kedepan atau 15 hari kedepan, Harga pada Pasar Manis rerata Rp. 9831 sedangkan pada Pasar Wage rerata Rp. 9981. Selain itu, pola prediksi harga komoditi cenderung melandai rendah. Hal ini menunjukkan terdapat kemungkinan harga komoditi turun. Visualisasi hasil prediksi harga pada masing-masing pasar dapat dilihat pada Gambar 6 dan Gambar 7. Sedangkan untuk harga harian dapat dilihat pada Tabel 8.



Gambar 6. Grafik Prediksi harga jual di Pasar Manis pada bulan September 2022



Gambar 7. Grafik Prediksi harga jual di Pasar Wage pada bulan September 2022

Tabel 8. Prediksi harga pangan pada bulan September 2022

Tanggal	Pasar (Harga)	
	Manis	Wage
2022-07-01	Rp. 9953	Rp. 9976
2022-07-02	Rp. 9942	Rp. 9972
2022-07-03	Rp. 9928	Rp. 9966
2022-07-04	Rp. 9912	Rp. 9958
2022-07-05	Rp. 9895	Rp. 9950
2022-07-06	Rp. 9876	Rp. 9941
2022-07-07	Rp. 9857	Rp. 9932
2022-07-08	Rp. 9836	Rp. 9922
2022-07-09	Rp. 9816	Rp. 9912
2022-07-10	Rp. 9795	Rp. 9902
2022-07-11	Rp. 9774	Rp. 9891
2022-07-12	Rp. 9752	Rp. 9880
2022-07-13	Rp. 9731	Rp. 9869
2022-07-14	Rp. 9710	Rp. 9859
2022-07-15	Rp. 9690	Rp. 9848

Pada Tabel 8. prediksi harga selama 15 hari pada bulan September 2022 rerata pada kedua Pasar yaitu Rp. 9874. Kemudian tren harga dari kedua pasar cenderung melandai menurun. Sehingga ini dapat dijadikan pengetahuan maupun informasi bagi petani ketika menjual hasil pertaniannya ke Pasar.

4. KESIMPULAN

Kepastian harga komoditas pangan sangat berpengaruh kepada produsen pangan, khususnya petani. Kepastian harga akan berdampak pada kesejahteraan petani. Prediksi harga komoditas pangan yang telah dilakukan, membantu petani dalam mengetahui fluktuatif harga pangan terutama harga komoditi di pasar tradisional seperti pasar Manis dan pasar Wage. Berdasarkan model prediksi yang diperoleh, model dengan akurasi *error* terendah (RMSE) yaitu 79.17%. Selain itu, harga pangan pada bulan September 2022 akan mengalami tren menurun atau harga komoditas cenderung rendah dengan harga rerata Rp 9831 di Pasar Manis dan Rp 9981 di Pasar Wage.

UCAPAN TERIMA KASIH

Penulis mengucapkan terima kasih kepada BELMAWA (Direktorat Jenderal Pembelajaran dan Kemahasiswaan) melalui program PKM (Program Kreativitas Mahasiswa) yang telah mendukung pembiayaan dalam kegiatan ini.

REFERENCES

- [1] [BPS] Badan Pusat Statistik, "Badan Pusat Statistik Kabupaten Banyumas," 2021.
- [2] BPS Jawa Tengah, "Jawa Tengah Dalam Angka 2021," pp. 1–935, 2021.
- [3] Badan Pusat Statistik, "Provinsi Jawa Tengah Dalam Angka Jawa Tengah Province in Figures 2022," 2022.
- [4] W. Afandi, S. N. Saputro, A. M. Kusumaningrum, H. Ardiansyah, M. H. Kafabi, and S. Sudianto, "Klasifikasi Judul Berita Clickbait menggunakan RNN-," *J. Pengemb. IT*, vol. 7, no. 2, pp. 85–89, 2022.
- [5] Sudianto, Y. Herdiyeni, A. Haristu, and M. Hardhienata, "Chilli quality classification using deep learning," 2020. doi: 10.1109/ICOSICA49951.2020.9243176.
- [6] S. Saadah and H. Salsabila, "Prediksi Harga Ponsel Menggunakan Metode Random Forest," *J. Komput. Terap.*, vol. 7, no. 1, pp. 24–32, 2021.
- [7] A. D. Arisandi and L. Atika, "Prediksi Mata Uang Bitcoin Menggunakan LSTM Dan Sentiment Analisis Pada Sosial Media," *J. Ilm. Komputasi*, vol. 19, no. 4, pp. 559–566, 2020, doi: 10.32409/jikstik.19.4.370.
- [8] F. Valencia, A. Gómez-Espinosa, and B. Valdés-Aguirre, "Price movement prediction of cryptocurrencies using sentiment analysis and machine learning," *Entropy*, vol. 21, no. 6, 2019, doi: 10.3390/e21060589.
- [9] Moch Faryz Rizkilloh and Sri Widiyanesti, "Prediksi Harga Cryptocurrency Menggunakan Algoritma Long Short Term Memory (LSTM)," *J. RESTI (Rekayasa Sist. dan Teknol. Informasi)*, vol. 6, no. 1, pp. 25–31, 2022, doi: 10.29207/resti.v6i1.3630.
- [10] J. Veri, Surmayanti, and Guslendra, "Prediksi Harga Minyak Mentah Menggunakan Jaringan Syaraf Tiruan Crude Oil Price Prediction Using Artificial Neural Network," vol. 21, no. 3, pp. 503–512, 2022, doi: 10.30812/matrik.v21i3.1382.
- [11] Sabar Sautomo and Hilman Ferdinandus Pardede, "Prediksi Belanja Pemerintah Indonesia Menggunakan Long Short-Term Memory (LSTM)," *J. RESTI (Rekayasa Sist. dan Teknol. Informasi)*, vol. 5, no. 1, pp. 99–106, 2021, doi: 10.29207/resti.v5i1.2815.
- [12] I. N. K. Wardana, N. Jawas, and I. K. A. A. Aryanto, "Prediksi Penggunaan Energi Listrik pada Rumah Hunian Menggunakan Long Short-Term Memory," *TIERs Inf. Technol. J.*, vol. 1, no. 1, pp. 1–11, 2020.
- [13] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," *Neural Comput.*, vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.
- [14] X. Bai, "Text Classification based on LSTM and Attention," pp. 29–32, 2018, doi: 10.1109/ICDIM.2018.8847061.



- [15] R. Jing, “A Self-attention Based LSTM Network for Text Classification,” *J. Phys. Conf. Ser.*, vol. 1207, no. 1, 2019, doi: 10.1088/1742-6596/1207/1/012008.
- [16] S. Sudianto, P. Wahyuningtias, H. W. Utami, U. A. Raihan, and H. N. Hanifah, “Comparison Of Random Forest And Support Vector Machine Methods On Twitter Sentiment Analysis (Case Study : Internet Selebgram Rachel Vennya Escape From Quarantine) Perbandingan Metode Random Forest Dan Support Vector Machine Pada Analisis Sentimen Twitt,” *Jutif*, vol. 3, no. 1, pp. 141–145, 2022.
- [17] S. Chandra Ayunda Apta, N. Trivetisia, N. A. Winanti, D. P. Martiyaningsih, T. W. Utami, and S. Sudianto, “Analisis Komparasi Algoritma Machine Learning untuk Sentiment Analysis,” *J. Pengemb. IT*, vol. 7, no. 2, pp. 80–84, 2022.
- [18] T. Chai and R. R. Draxler, “Root mean square error (RMSE) or mean absolute error (MAE),” *Geosci. Model Dev.*, vol. 7, no. 3, pp. 1247–1250, 2014, doi: 10.5194/gmd-7-1247-2014.